华南理工大学学报(自然科学版)
第47卷 第8期 Journal of South China University of Technology (Natural Science Edition) Vol.47 No.8
2019年8月 August 2019

doi: 10.12141/j.issn.1000-565X.180273

基于标签深度分析的音乐自动标注算法

王振宇 张睿 高雨轩 萧永乐

(华南理工大学 软件学院,广东 广州 510006)

摘 要: 尽管深度神经网络算法在标签自动标注领域已取得一定的成果,但对于包含大量噪声标签的真实音乐数据集仍存在自动标注效果差的问题.为此,文中通过对音乐标签进行表示学习,挖掘音乐标签与音频特征之间的潜在关系,提出了基于标签深度分析的音乐自动标注算法.该算法先通过多层级卷积网络提取音频特征,再通过音乐标签向量的表示学习来降低噪声数据对音乐自动标注网络的不良影响.在真实音乐标注数据集上的实验结果表明,该算法能取得更高的平均受试者特征曲线下面积,标注效果优于其他自动标注算法.

关键词: 音乐自动标注;深度神经网络;音乐标签向量

中图分类号: TP181 **文章编号:** 1000-565X(2019)08-0071-06

近年来,音乐数字化已经成为趋势,网上可访问的歌曲数量已超过3000万首,音乐的种类越来越丰富.丰富的音乐标签信息可以帮助在线音乐网站在海量音乐的组织、检索、发现等应用上提高服务质量,对于在线音乐流媒体应用来说具有很高的潜在经济价值,因此音乐自动标注技术受到学术界和工业界的关注.

音乐标签是数字化音乐服务的重要组成部分.在线音乐网站和音乐检索工具通常会给歌曲标注音乐标签,以此作为分类检索的依据.音乐标签是指能够表达音乐特性的高层次描述性词语[1],如描述心情的"快乐"、"悲伤",描述流派的"雷鬼"、"摇滚",描述乐器的"吉他"、"器乐"等.除此之外,数字化音乐网站的检索、推荐和页面导航的服务质量很大程度上依赖于音乐标签的质量.然而,数字化音乐网站新上架的歌曲、冷门歌曲通常具有很少的标签信息,因此会出现一些常见问题[2].例如,在大规模音乐曲库中,热度较低的长尾音乐可能由于缺少必要的音乐标签而很少被推荐或访问,进而得到用户或社区标注的机会更少,形成负反馈效应.虽然专家标注能够解决歌曲长尾问题,然而专家标注的成本高昂,无法应用于大规模音乐曲库.因此,根据音乐的音频信息进行音乐标签自动标注具有极高的研究价值.

深度神经网络(DNN)目前在音乐标签自动标注领域已经有一些成功的应用.基于深度神经网络的音乐标签自动标注方法主要分为无监督学习和有监督学习两类.在无监督学习方法中,首先是挖掘音频信号帧级别上对标签标注有效的帧结构,得到高维空间上的稀疏表达,从而构造出特征集合,代表方法有K-均值[3-5]、稀疏编码[6-7]和受限玻尔兹曼机(RBM)[8]等,这样得到的音频特征是单层次的[9];然后将特征集合输入到分类器中,得到标签预测结果.这种无监督的单层次特征学习方法能够从特征集合中捕获有效的音频特征[10].对于有监督学习方法,通常直接将整个歌曲的音频作为卷积神经网络的输入,通过多层次架构挖掘音频的多层次特征,得

收稿日期: 2018-06-05

基金项目: 广东省科技计划项目(2015B010131003);广州市产业技术重大攻关计划项目(201802010025);广州市高校创新创业教育平台建设重点项目(2019PT103)

Foundation item: Supported by the Science and Technology Planning Project of Guangdong Province(2015B010131003)

作者简介: 王振宇(1967-),男,博士,教授,主要从事云计算、数据挖掘、社会计算研究.E-mail: wangzy@scut.edu.cn

?1994-2019 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

到更好的标注结果[11-14].

大规模音乐数据集通常包含非专家用户所标注的音乐标签[15]. 由于标签体系存在异构性及流派、情感等主观标签类型,标签噪声问题普遍存在,给音乐标签的自动化标注带来困难. 改变 DNN 的结构、优化网络参数无法很好地解决该问题,需要设计相应的网络结构和算法,挖掘音频样本的深层次信息,以减少噪声数据的影响.

针对上述噪声标签问题,文中提出了基于标签深度分析的音乐自动标注算法,结合卷积神经网络和表示学习方法,通过融合音频特征和音乐标签特征来解决音乐自动标注中的噪声问题,并在 3 大规模数据集上验证该算法的有效性.

1 算法描述

文中基于标签深度分析的音乐自动标注算法包含 4 个模块: 音频特征提取、标签向量提取、特征聚合和标签预测,其框架如图 1 所示. 音频特征提取模块通过有监督学习对多层卷积网络[16-18]进行预训练,初步优化网络参数. 标签向量提取模块利用卷积网络对音乐标签进行表示学习,得到音乐标签的向量化表示. 特征聚合模块通过向量池化、线性变换和连接实现音频特征与标签向量特征的融合. 标签预测模块根据融合特征预测音频标签,通过有监督学习对网络参数进行微调.

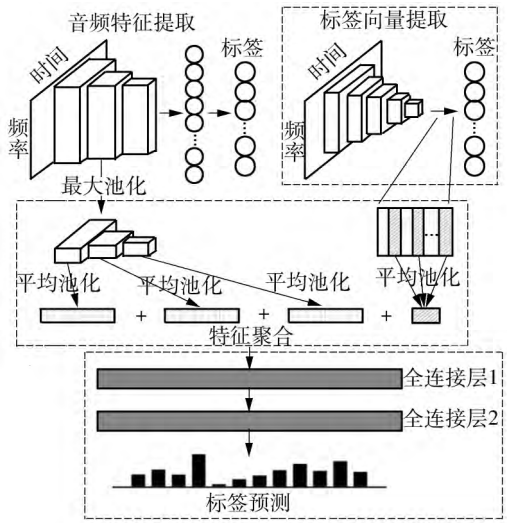

图 1 基于标签深度分析的音乐自动标注算法框架

Fig. 1 Architecture of music auto-tagging algorithm based on deep analysis on labels

1.1 音频特征提取

由于单一的网络隐藏层难以有效地提取和表征音乐自动标注任务所需的关键信息,因此文中采用多层卷积神经网络[19]对音频特征进行逐层提取. 首先将原始音频进行转换得到梅尔频谱图,并采用非线性函数进行压缩; 然后将预处理后的图像作为输入特征,使用多层级卷积神经网络对输入特征进行逐层提取和抽象,捕捉与音乐自动标注任务相关的有效信息.

音频特征提取模块由 3 层卷积神经网络组成. 考虑到由音频转换得到的梅尔频谱图中低频信号特征与高频信号特征具有不同的含义,文中使用一维卷积核对频谱图进行卷积操作. 在各卷积层后通过批规范化操作[20]和指数线性激活函数(ELU)[21]对网络层输出进行非线性变换,同时使用残差连接以进一步提升模型的泛化能力.

该模块的网络超参数设置如图 2 所示. 其中,一维卷积层参数分别表示卷积通道数量和卷积核的大小,池化层参数表示池化宽度,全连接层参数表示该网络层包含的神经元个数. 此外,在每个池化层后采用了随机丢弃算法[22]以防止模型过拟合,丢弃系数设为 0.5.

输入层(1,96,1350)	
一维卷积层和最大池化层	(128,3)和(3)
归一化层 - ELU激活函数	
一维卷积层和最大池化层	(128,3)和(3)
归一化层 - ELU激活函数	
一维卷积层和最大池化层	(256,3)和(3)
归一化层 - ELU激活函数	
全连接层	(256)
输出层(50)	

图 2 音频特征提取网络架构

Fig. 2 Architecture of audio feature extraction network

1.2 标签向量提取

由于音乐标签通常基于不同标准(如“年代”、“风格”等)进行划分,因此文中提出的音乐标签向量提取方法通过表示学习技术获得音乐标签的向量化表示,能够学习到不同维度下音乐标签共现的统计学规律,以利用部分已标注的音乐标签指导模型进行准确预测.

音乐标签向量提取网络采用类似于文献[1]的二维卷积网络结构. 首先通过监督学习训练模型进行标签预测直到模型收敛,进而通过提取最后一个池化层与分类输出层之间的全连接参数矩阵得到音乐标签的表示学习结果. 该参数矩阵可表示为矩阵

?1994-2019 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

$W \in \mathbf{R}^{N \times M}$,其中 N 为最后一个池化层的神经元数量(文中取 32),M 为最终预测标签的个数(文中取 50). 该矩阵的第 k 列是一个 N 维的向量,对应于第 k 个音乐标签的标签向量.

音乐标签向量提取网络的结构与超参数设置如图 3 所示. 其中,二维卷积层参数分别表示卷积通道数量、(卷积核长度,卷积核宽度),最大池化层参数分别表示池化长度和宽度. 此外,每个卷积层同样通过批规范化和 ELU 激活函数进行非线性变换.

输入层(1,96,1350)	
二维卷积层和最大池化层	(32,(3,3))和(2,4)
规范层 - ELU激活函数	
二维卷积层和最大池化层	(32,(3,3))和(3,4)
规范层 - ELU激活函数	
二维卷积层和最大池化层	(32,(3,3))和(2,5)
规范层 - ELU激活函数	
二维卷积层和最大池化层	(32,(3,3))和(2,4)
规范层 - ELU激活函数	
二维卷积层和最大池化层	(32,(3,3))和(4,4)
规范层 - ELU激活函数	
全连接层	(50)
输出层(50)	

图 3　标签向量提取网络架构

Fig. 3　Architecture of label vector extraction network

通过上述表示学习方法,音乐标签向量提取网络能够自动学习到音乐标签在低维连续稠密空间中的向量表示. 可以认为音乐标签向量能够反映音乐标签共现的统计规律. 当音乐存在部分标注时,后续模块通过特征聚合能够利用音乐标签向量指导模型产生更加精准的自动标注结果.

1.3　特征聚合

特征聚合模块通过将音频特征模块得到的音频层级特征和标签向量提取模块学习到的音乐标签向量进行有效融合,产生更丰富的音频特征表示.

该模块首先采用最大池化和平均池化操作对音频层级特征进行特征总结,得到多个一维音频特征向量. 其中,最大池化操作提取卷积结果中的代表性特征,平均池化操作总结片段特征,以捕捉卷积结果中的局部信息[23].

对于带有部分音乐标签标注的输入音频,特征聚合模块利用音乐标签向量作为额外的先验知识构造标签特征向量. 具体的,考虑到每个音频上已有标注标签的数量不同,文中算法将已标注标签的向量进行平均池化,计算公式如下:

$$\boldsymbol{B} = \frac{1}{c} \sum_{i=1}^{N} A_i * \boldsymbol{W}_i \tag{1}$$

式中,$\boldsymbol{B}$ 为当前音频的标签特征向量,c 为该音频已有标注标签的个数,N 为标签类别总数,$\boldsymbol{W}_i$ 为第 i 个标签的表示向量,A_i 为状态值(当该音频已标注第 i 个标签时取值为 1,否则为 0). 对于不具备已标注标签的音频,模型采用缺省向量进行表示,缺省向量在标签预测模型训练时自适应学习.

最后,特征聚合模块将各级池化层得到的多个一维音频特征向量和标签特征向量分别进行批规范化操作,并将向量进行线性拼接,得到最终的融合特征向量.

1.4　标签预测

标签预测模块以聚合特征作为模型的输入,训练一个额外的全连接网络作为分类器,该网络由两个全连接的隐藏层和一个输出层构成. 其中,隐藏层的神经元个数依次设置为 1024 和 512. 全连接层采用 Dropout 机制来提高模型的泛化能力,Dropout 概率设置为 0.5. 标签预测网络的输出层使用 Sigmoid 函数对计算结果进行归一化,将各个标签的预测值映射到 [0,1] 区间上.

2　实验与结果分析

2.1　实验数据

为了评估文中基于标签深度分析的音乐自动标注算法的效果,分别在 3 个数据集(MSD 数据集[24]、MTAT 数据集[25]、一个真实商业数据集)上进行实验. 为了便于实验结果的比较,文中采取与文献[1,12]相同的标签选取方法,采用的预测标签只包括数据集中出现频率最高的 50 个标签,如果一首歌曲的标签不包含这 50 个标签中的任何一个,那么该歌曲将被过滤. 此外,所有数据集中的音频文件都被剪切为时长 30 s 的音频片段,真实商业数据集中的歌曲通常长达几分钟,因此对真实商业数据集中的每首歌曲都进行无放回的抽样,得到多个时长为 30 s 的音频片段.

数据集的数据划分情况如表 1 所示,其中,训练集数据样本用于模型训练,验证集样本用于初步评估和调整模型超参数,测试样本用于评估和验证模型的泛化能力.

表 1　实验数据分布情况

Table 1　Distribution of experimental data

数据集	数据样本个数		
	训练集	验证集	测试集
MSD	168158	24022	48045
MTAT	19397	1616	4850
商业数据集	246064	35152	70304

?1994-2019 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

2.2 实验细节

3个数据集的音频文件都是MP3格式,统一使用16 kHz作为采样频率.首先将每个音频剪辑转换成具有1 350帧的梅尔频谱图,其中分箱数为96,短时傅里叶变换窗口的跳跃长度为256,使用非线性函数$\log_2(1+C|A|)$压缩振幅A.这样数据集中的每个音频样本输入神经网络的尺寸为(1,96,1 350),其中1为通道数,96为梅尔频谱的分箱大小,1 350为帧数.使用指数线性激活函数(ELU)作为音频特征提取网络和标签向量提取网络的隐藏层激活函数.为了防止过拟合,实验中所有网络的Dropout参数均设为0.5,损失函数为交叉熵损失,使用Sigmoid函数作为输出层的激活函数,实验的主要评估指标为受试者特征曲线下面积(AUC).

2.3 实验结果与分析

2.3.1 多层级聚合有效性验证

本实验在MSD和MTAT数据集上验证音频特征提取网络的特征提取能力.分别记音频特征提取网络中的3个卷积层为L1、L2和L3,数字表示网络层级.为了验证不同的特征组合方式对标注效果的影响,本实验将3种不同深度的卷积层特征进行两两线性聚合(记为L1+L2、L1+L3、L2+L3)和同时线性聚合(记为L1+L2+L3).为了验证聚合特征相比单层特征更具有效性,在对比实验中加入了独立的L1、L2、L3特征.训练过程中所有音频的音乐标签向量均被设置为缺省标签向量,以排除音乐标签向量对实验结果的影响.实验结果如表2所示.在仅使用单层级特征进行音乐标签预测的情况下,使用L3特征进行预测的表现比仅用L1或L2更好.而使用聚合特征的表现优于单层特征,其中L1+L2+L3的聚合方式取得最好的表现.

表2 不同层级音频特征组合下的AUC值

Table 2 AUC values under combinations of audio feature from different levels

数据集	AUC						
	L1+L2+L3	L1+L2	L1+L3	L2+L3	L3	L2	L1
MSD	0.8858	0.8828	0.8844	0.8852	0.8825	0.8811	0.8694
MTAT	0.8996	0.8986	0.8983	0.8989	0.8977	0.8976	0.8935

同时,从实验结果中可以观察到,采用聚合特征进行自动标注时同一种层级特征在不同数据集上对模型性能的影响不同.在MTAT数据集上,L2特征对模型标注效果具有显著的影响;而在MSD数据集上,L3特征是影响AUC表现的主要因素.文中认为是两个数据集的数据分布情况导致了这一差异,MTAT数据集拥有更多乐器类标签,而MSD数据集包含了大量的风格和情感标签.

2.3.2 标签向量的影响实验

本实验在MSD数据集上分析特征提取模块的音乐标签表示学习效果,以验证音乐标签向量对音乐自动标注算法的影响.实验对比了标注模型在不使用标签向量、使用缺省标签向量和文中提出的深度标签分析(DAL)算法的标注效果.实验结果如表3所示.从表中可知:在标注模型中引入音乐标签向量,能够显著提高模型的标注效果;相比于缺省标签向量,DAL算法能够通过表示学习,有效地挖掘音乐标签之间的深层关系,提升AUC;使用缺省标签向量与不使用标签向量的对比结果说明,模型能够在训练过程中对缺省向量进行微调,从而利用缺省标签向量来提升模型的性能.

表3 标签向量在不同标签上的AUC增量

Table 3 AUC increment of label vector for different tags

类别	音乐	AUC增量/10^{-4}		
		未用标签向量	使用缺省向量	标签深度分析
流派	嘻哈	1	35	21
	R$B	2	15	45
	重金属	2	97	110
	爵士	3	8	50
	硬摇滚	1	16	75
	独立摇滚	2	25	110
	流行	3	60	164
	摇滚	2	10	73
	另类音乐	1	103	124
情感	老歌	2	33	117
	优美	1	12	295
	平静	2	191	176
	琅琅上口	1	179	419
乐器	器乐	2	68	114
	女声	3	10	177
	吉他	1	149	274
年代	80年代	1	82	107
	70年代	2	10	142
	90年代	2	249	280

2.3.3 音乐标注算法的实验结果对比

分别在MSD数据集、MTAT数据集和真实商业数据集上采用文中提出的DAL算法与目前先进的音乐自动标注算法进行对比,实验结果如表4所示.由表中可知,文中提出的算法在MSD数据集和商业

?1994-2019 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

数据集上的表现优于其他模型,在 MTAT 数据集上与最好的算法(PCNN) 表现相近. 通过分析可知,这是由于 MTAT 数据集中噪声数据的比例相对另外两个数据集较少.

表 4　几种算法的 AUC 结果对比

Table 4　Comparison of AUC results among several algorithms

模型	MTAT	MSD	商业数据集
多尺度特征学习[5]	0.8980		
一维 CNN[12]	0.8815		
PCNN[26]	0.9013		
FCN[1]	0.8940	0.8510	0.7950
CRNN[27]		0.8620	0.7860
二维 CNN[28]			0.6720
时序特征学习网络[29]			0.6890
音频特征提取网络	0.8996	0.8858	0.8157
DAL 算法(缺省标签向量)	0.8979	0.8902	0.8324
DAL 算法	0.8992	0.8931	0.8497

此外,基于标签深度分析的音乐标注算法的表现明显优于仅使用卷积神经网络进行特征提取的模型,这进一步说明了标签向量提取模块的有效性. 与采用缺省标签向量的 DAL 算法的结果对比表明,文中提出的标签向量提取算法能够有效地对音乐标签进行表示学习.

3　结论

文中提出了基于标签深度分析的音乐自动标注算法. 该算法结合基于卷积网络的音频特征提取和音频标签表示学习,通过聚合音频特征和标签特征实现音乐标签的自动标注. 在 MSD 数据集、MTAT 数据集和真实商业数据集上的实验结果表明,文中算法在带有噪声的音乐数据集上的音乐标注效果优于其他先进的音乐标注算法.

文中算法仅利用音频特征对音乐进行自动化标注,没有充分利用音乐视频和歌词等其他模态的信息. 今后将进一步探讨利用多模态信息对音乐进行标注的方法.

参考文献:

[1] CHOI K,FAZEKAS G,SANDLER M. Automatic tagging using deep convolutional neural networks [C] // Proceedings of the 17th International Society for Music Information Retrieval Conference. New York: International Society of Music Information Retrieval,2016: 805-811.

[2] LAMERE P. Social tagging and music information retrieval [J]. Journal of New Music Research,2008,37(2): 101-114.

[3] WÜLFING J,RIEDMILLER M A. Unsupervised learning of local features for music classification [C] // Proceedings of the 13th International Society for Music Information Retrieval Conference. Porto: International Society of Music Information Retrieval,2012: 139-144.

[4] NAM J,HERRERA J,SLANEY M,et al. Learning sparse feature representations for music annotation and retrieval [C] // Proceedings of the 13th International Society for Music Information Retrieval Conference. Porto: International Society of Music Information Retrieval,2012: 565-570.

[5] DIELEMAN S,SCHRAUWEN B. Multiscale approaches to music audio feature learning [C] // Proceedings of the 14th International Society for Music Information Retrieval Conference. Curitiba: Pontifícia Universidade Católica do Paraná,2013: 116-121.

[6] HENAFF M,JARRETT K,KAVUKCUOGLU K,et al. Unsupervised learning of sparse features for scalable audio classification [C] // Proceedings of the 12th International Society for Music Information Retrieval Conference. Miami: International Society of Music Information Retrieval, 2011: 681-686.

[7] VAIZMAN Y,MCFEE B,LANCKRIET G. Codebook-based audio feature representation for music information retrieval [J]. IEEE/ACM Transactions on Audio,Speech and Language Processing,2014,22(10): 1483-1493.

[8] SCHLUTER J,OSENDORFER C. Music similarity estimation with the mean-covariance restricted Boltzmann machine [C] // Proceedings of 10th International Conference on Machine Learning and Applications and Workshops. Honolulu: IEEE,2011: 118-123.

[9] SU L,YEH C C M,LIU J Y,et al. A systematic evaluation of the bag-of-frames representation for music information retrieval [J]. IEEE Transactions on Multimedia,2014,16 (5): 1188-1200.

[10] COATES A,NG A,LEE H. An analysis of single-layer networks in unsupervised feature learning [J]. Journal of Machine Learning Research,2011,15: 215-223.

[11] 王诗俊,陈宁. 基于混合判别受限波兹曼机的音乐自动标注算法 [J]. 华东理工大学学报(自然科学版) , 2017,43(4): 540-545.
WANG Shi-jun,CHEN Ning. Annotating music with hybrid discriminative restricted Boltzmann machines [J]. Journal of East China University of Science and Technology(Natural Science Edition) ,2017,43(4): 540-545.

[12] DIELEMAN S,SCHRAUWEN B. End-to-end learning for music audio [C] // Proceedings of IEEE International Conference on Acoustics,Speech and Signal Processing. Florence: IEEE,2014: 6964-6968.

[13] 黎鹏,陈宁. 基于降噪自动编码器特征学习的音乐自动标注算法 [J]. 华东理工大学学报(自然科学版) , 2017,43(2): 241-247.

?1994-2019 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

LI Peng, CHEN Ning. Feature learning for music auto-tagging using denoising autoencoder [J]. Journal of East China University of Science and Technology (Natural Science Edition), 2017, 43(2): 241-247.

[14] 龚强. 深度学习在音乐自动标注中的应用 [D]. 北京: 北京交通大学, 2017.

[15] CANTADOR I, KONSTAS I, JOSE J M. Categorising social tags to improve folksonomy-based recommendations [J]. Web Semantics: Science, Services and Agents on the World Wide Web, 2011, 9(1): 1-15.

[16] ZEILER M D, FERGUS R. Visualizing and understanding convolutional networks [C] // Proceedings of the 13th European Conference on Computer Vision. Zurich: Springer, 2014: 818-833.

[17] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition [C] // Proceedings of 2016 IEEE Conference on Computer Vision and Pattern Recognition. Las Vegas: IEEE, 2016: 770-778.

[18] SZEGEDY C, LIU W, JIA Y, et al. Going deeper with convolutions [C] // Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition. Boston: IEEE, 2015: 1-9.

[19] CHOI K, JOO D, KIM J. Kapre: on-GPU audio preprocessing layers for a quick implementation of deep neural network models with Keras [EB/OL]. (2017-06-19) [2018-05-10]. https://arxiv.org/abs/1706.05781.

[20] IOFFE S, SZEGEDY C. Batch normalization: accelerating deep network training by reducing internal covariate shift [C] // Proceedings of the 32nd International Conference on Machine Learning. Lille: International Machine Learning Society, 2015: 448-456.

[21] CLEVERT D A, UNTERTHINER T, HOCHREITER S. Fast and accurate deep network learning by exponential linear units(elus) [EB/OL]. (2016-02-22) [2018-05-10]. https://arxiv.org/abs/1511.07289.

[22] SRIVASTAVA N, HINTON G, KRIZHEVSKY A, et al. Dropout: a simple way to prevent neural networks from overfitting [J]. The Journal of Machine Learning Research, 2014, 15(1): 1929-1958.

[23] NAM J, HERRERA J, LEE K. A deep bag-of-features model for music auto-tagging [EB/OL]. (2016-10-16) [2018-05-10]. https://arxiv.org/abs/1508.04999.

[24] BERTIN-MAHIEUX T, ELLIS D P W, WHITMAN B, et al. The million song dataset [C] // Proceedings of the 12th International Society for Music Information Retrieval Conference. Miami: International Society of Music Information Retrieval, 2011: 591-596.

[25] LAW E, WEST K, MANDEL M I, et al. Evaluation of algorithms using games: the case of music tagging [C] // Proceedings of the 10th International Society for Music Information Retrieval Conference. Kobe: International Society of Music Information Retrieval, 2009: 387-392.

[26] LIU J Y, JENG S K, YANG Y H. Applying topological persistence in convolutional neural network for music audio signals [EB/OL]. (2016-08-26) [2018-05-10]. https://arxiv.org/abs/1608.07373.

[27] CHOI K, FAZEKAS G, SANDLER M, et al. Convolutional recurrent neural networks for music classification [C] // Proceedings of 2017 IEEE International Conference on Acoustics, Speech and Signal Processing. New Orleans: IEEE, 2017: 2392-2396.

[28] KERELIUK C, STURM B L, LARSEN J. Deep learning and music adversaries [J]. IEEE Transactions on Multimedia, 2015, 17(11): 2059-2071.

[29] JEONG I Y, LEE K. Learning temporal features using a deep neural network and its application to music genre classification [C] // Proceedings of the 17th International Society for Music Information Retrieval Conference. New York: International Society of Music Information Retrieval, 2016: 434-440.

Music Auto-tagging Algorithm Based on Deep Analysis on Labels

WANG Zhenyu ZHANG Rui GAO Yuxuan XIAO Yongle

(School of Software Engineering, South China University of Technology, Guangzhou 510006, Guangdong, China)

Abstract: Deep neural network algorithms have made breakthroughs in automatic labeling tasks, but it is still hard to solve the noise data problem in real music dataset. A music auto-tagging algorithm based on deep analysis on labels (DAL) which captures the potential relationship between audio features and music tags was proposed. The algorithm first extracts the audio features through a multi-level convolutional network, and then learn the vector representation of music tags to reduce the adverse effects of noise data. The experimental results show that the proposed algorithm can achieve higher mean area under receiver operating characteristic curve (AUROCC) and outperform other auto-tagging methods.

Key words: music auto-tagging; deep neural network; music label vector

?1994-2019 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net